

Latihan Exam Modul 3

1. Di bawah ini yang bukan merupakan model atau algoritma yang umum digunakan dalam supervised learning adalah
 - a. Linear Regression
 - b. Logistic Regression
 - c. KMeans**
 - d. Decision Tree
 - e. Adaptive Boosting

2. Misalkan Anda diminta untuk mengimplementasikan *fraud detection system* pada sebuah transaksi keuangan. Diberikan beberapa pernyataan berikut ini.
 - 1) Sistem Anda akan menghasilkan nilai yaitu besarnya peluang sebuah transaksi untuk dikenali sebagai Fraud (penipuan).
 - 2) Jumlah uang dalam transaksi dapat menjadi salah satu feature untuk melakukan prediksi.
 - 3) Anda harus mengimplementasikan sistem ini dengan pendekatan machine learning.
 - 4) Anda harus memiliki jumlah transaksi fraud dan non-fraud yang sama untuk melatih machine learning model Anda.

Pernyataan yang kurang tepat adalah...

- a. 1, 2, 4
 - b. 2, 4
 - c. 3, 4**
 - d. 2, 3
 - e. 1, 4
-
3. Perhatikan persamaan model multiple linear regression di bawah ini.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

Pernyataan yang tepat adalah...

- a. Komponen dalam kotak kuning adalah slope
 - b. Komponen dalam kotak hijau adalah explanatory variable
 - c. Komponen dalam kotak merah adalah intercept
 - d. Komponen dalam kotak biru adalah independent variable
 - e. Komponen dalam kotak hijau adalah response variable**
-
4. Pada kasus regresi, metode Least Squares (OLS) dapat digunakan untuk mengestimasi nilai parameter model dengan cara mencari
 - a. Jumlah kuadrat dari nilai hasil prediksi dan data observasi yang sekecil mungkin
 - b. Jumlah kuadrat selisih dari nilai hasil prediksi dengan data observasi yang sekecil mungkin**

- c. Jumlah kuadrat dari nilai hasil prediksi dan data observasi yang mendekati 1
 - d. Jumlah kuadrat selisih dari nilai hasil prediksi dengan data observasi yang mendekati 1
 - e. Tidak ada jawaban yang benar
5. Fungsi `calculate_metric` pada kode di bawah ini akan menghitung sebuah evaluation metric yaitu

```
def calculate_metric(y_act, y_pred):  
    list_error = []  
    n = len(y_pred)  
  
    for i in range(n):  
        error = y_act[i] - y_pred[i]  
        list_error.append(error)  
  
    return np.sqrt(np.mean(np.square(list_error)))
```

- a. MSE
 - b. MAE
 - c. MAPE
 - d. RMSE**
 - e. R square
6. Dalam kasus klasifikasi sistem pendeteksi kanker, di mana orang yang menderita kanker diasumsikan sebagai positive class, false positive rate menandakan ...
- a.** Persentase jumlah pasien tidak kanker yang dideteksi sebagai pasien kanker
 - b. Persentase jumlah pasien kanker yang dideteksi sebagai pasien tidak kanker
 - c. Jumlah pasien tidak kanker yang dideteksi sebagai pasien kanker
 - d. Jumlah pasien kanker yang dideteksi sebagai pasien tidak kanker
 - e. Persentase jumlah pasien tidak kanker yang dideteksi sebagai pasien tidak kanker
7. Pada decision tree classification, splitting akan berhenti dilakukan jika terpenuhi kondisi-kondisi berikut ini:
- 1) Kedalaman tree sudah mencapai ketentuan
 - 2) Jumlah elemen pada node sebelum melakukan splitting kurang dari ketentuan
 - 3) Jumlah elemen pada node setelah melakukan splitting kurang dari ketentuan
 - 4) Jumlah elemen pada node setelah melakukan splitting lebih dari ketentuan
 - 5) Seluruh elemen pada leaf masuk ke dalam satu kelas saja
- Pernyataan yang tepat ada pada nomor ...
- a. 1, 2, 3
 - b. 1, 2, 4
 - c. 1, 2, 3, 5**
 - d. 1, 2, 4, 5

e. 2, 4, 5

8. Di bawah ini yang merupakan pernyataan yang pasti benar mengenai decision tree yaitu

- a. Decision tree dapat digunakan untuk melakukan prediksi target yang bersifat continuous
- b. Nilai parameter min_samples_split yang besar akan menghasilkan tree yang dalam/besar
- c. Pada bagian bawah tree, nilai gini impurity cenderung lebih tinggi
- d. Nilai parameter min_samples_leaf yang besar akan menghasilkan tree yang dalam/besar
- e. Nilai parameter max_depth yang besar pasti akan menghasilkan jumlah node yang banyak

9. Bagian yang paling mungkin menyebabkan masalah evaluasi model pada potongan kode di bawah ini terdapat pada

```
1  import pandas as pd
2  import numpy as np
3  from sklearn.tree import DecisionTreeRegressor
4  from sklearn.metrics import mean_squared_error
5  from sklearn.model_selection import train_test_split
6
7  df = pd.read_csv('melb_data.csv')
8
9  X = df.drop(columns='price')
10 y = df['price']
11
12 tree = DecisionTreeRegressor()
13 tree.fit(X,y)
14
15 X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
16
17 y_pred = tree.predict(X_test)
18 print('RMSE', np.sqrt(mean_squared_error(y_test, y_pred)))
19
```

- a. Pada baris ke-7, untuk membaca dataset seharusnya np.read_csv()
- b. Pada baris ke-15, proses splitting train set dan test set seharusnya sebelum model training
- c. Pada baris ke-15, train_test_split seharusnya menggunakan parameter stratify=y
- d. Pada baris ke-17, untuk prediksi seharusnya tree.predict(y_test)
- e. Pada baris ke-18, RMSE digunakan untuk evaluasi kasus regresi

10. Perhatikan tabel hasil training dan evaluation dari 3 kandidat model berikut ini.

No	Algoritma	Jumlah Feature	Accuracy (train set)	Accuracy (test set)
1	Logistic Regression	5	0.61	0.61
2	Decision Tree	30	0.93	0.75
3	XGBoost	15	0.85	0.83

Pernyataan yang tepat mengenai tabel di atas adalah ...

- a. Model no.3 mengalami overfitting
- b. Model no.1 adalah model terbaik karena modelnya paling general/stabil
- c. Model no.2 mengalami underfitting
- d. Model no.1 kemungkinan dapat ditingkatkan performanya dengan menambah jumlah feature**
- e. Model no.2 kemungkinan dapat ditingkatkan performanya dengan menambah jumlah feature

11. Di bawah ini yang bukan merupakan strategi untuk dapat menghindari overfitting yaitu ...

- a. Menambah jumlah data untuk training model
- b. Menerapkan regularization dengan nilai parameter penalty yang tinggi
- c. Menggunakan polynomial features pada model**
- d. Mengurangi kompleksitas model
- e. Mengurangi jumlah fitur

12. Kondisi di bawah ini merupakan beberapa penyebab dari underfitting, kecuali

- a. Menggunakan nilai k (jumlah neighbor) yang besar untuk K-Nearest Neighbours
- b. Menggunakan model linear pada data yang tidak linear
- c. Melatih model dengan sedikit feature
- d. Membuat decision tree dengan entropy sebagai splitting criterion**
- e. Membuat decision tree dengan depth = 1

13. Di antara beberapa contoh categorical variable di bawah ini, yang paling mungkin di-encode menggunakan teknik ordinal encoding yaitu

- a. Jenjang karir/Pangkat**
- b. Jenis kelamin
- c. Nama negara
- d. Status merokok (ya/tidak)
- e. Nama kota

14. Perhatikan potongan kode di bawah ini.

```
from sklearn.preprocessing import OneHotEncoder

mpg_train = np.array(X_train['MPG']).reshape(-1,1)
mpg_test = np.array(X_test['MPG']).reshape(-1,1)

encoder = OneHotEncoder()

mpg_train_encoded = encoder.fit_transform(mpg_train)
mpg_test_encoded = encoder.transform(mpg_test)

print('No of unique value:', X_train['MPG'].nunique())
print('No of new columns:', mpg_train_encoded.shape[1])
```

Output:

No of unique value: 9

No of new columns: ???

Berapa jumlah kolom yang dihasilkan dari proses One Hot Encoding di atas?

- a. 8
- b. 9**
- c. 4
- d. 1
- e. 81

15. Apabila terdapat missing values pada sejumlah kolom sebuah dataset, strategi yang mungkin untuk dilakukan yaitu sebagai berikut, kecuali

- a. mengisi missing value pada suatu kolom numerikal dengan suatu nilai berdasarkan hasil regresi dari nilai pada kolom lainnya
- b. mengisi missing value dengan mode jika kolomnya kategorikal
- c. mengisi missing value dengan mean jika kolomnya numerikal
- d. menghapus baris yang punya missing value
- e. mengisi missing value dengan mean jika kolomnya kategorikal**

16. Pada model-based feature selection, pemilihan feature dapat dilakukan diantaranya dengan

- a. Melihat feature importance pada model seperti decision tree dan random forest
- b. Memilih feature berdasarkan domain knowledge
- c. Melatih model dengan sedikit feature, lalu menambahkan feature satu per satu sambil menghitung sebuah metric
- d. Memilih feature dengan melihat korelasi antara feature dengan target
- e. Melatih model dengan seluruh feature, lalu menghilangkan feature satu per satu sambil menghitung sebuah metric**

17. Diberikan sebuah confusion matrix dari model klasifikasi seperti di bawah ini:

	Predicted: YES	Predicted: NO
Actual: YES	1000	120
Actual: NO	20	500

Apabila 'YES' diasumsikan sebagai positive class, berapa nilai precision?

- a. 0.892
- b. 0.980**
- c. 0.806
- d. 0.961
- e. 0.5

18. Anda seorang Data Scientist di sebuah perusahaan FinTech dan diminta untuk mengimplementasikan sebuah sistem pendeteksi nasabah gagal bayar (default). Perusahaan Anda menilai bahwa kerugian ketika salah memprediksi nasabah yang mampu melunasi pembayaran sebagai nasabah gagal bayar (default) lebih besar dibanding kerugian ketika salah memprediksi nasabah gagal bayar sebagai nasabah yang mampu melunasi pembayaran.

Metric yang perlu coba diminimalkan nilainya oleh model Anda adalah...

- a. F1 score
- b. Precision
- c. Recall
- d. False Positive Rate**
- e. False Negative Rate

19. Berdasarkan kode di bawah ini, jumlah kombinasi nilai hyperparameter yang akan di-fitting adalah

```

from sklearn.model_selection import RandomizedSearchCV
from sklearn.tree import DecisionTreeClassifier

param_grid = {
    'max_depth': list(range(2, 7, 2)),
    'min_samples_leaf': [2, 4, 6, 8],
    'criterion': ['gini', 'entropy']
}

tree = DecisionTreeClassifier()

search_cv = RandomizedSearchCV(
    estimator= tree,
    param_distributions= param_grid,
    n_iter= 20,
    random_state=2020
)

search_cv.fit(X_train, y_train)

```

- a. 9
 - b. 40
 - c. 24
 - d. 48
 - e. 20**
20. Untuk memperoleh pengukuran evaluasi model berupa rata-rata dari kuadrat selisih antara hasil prediksi dengan data observasi yang sesungguhnya, metric yang dapat digunakan yaitu
- a. MAE
 - b. MSE**
 - c. RMSE
 - d. MAPE
 - e. R square