

21. Di bawah ini yang merupakan strategi yang kurang tepat dalam mengatasi kasus imbalance class adalah
- a. Melakukan oversampling
 - b. Melakukan undersampling
 - c. Mengumpulkan lebih banyak data pada minority class
 - d. Melakukan feature engineering
 - e. Menambah data pada majority class**
22. Salah satu strategi dalam ensemble learning di mana terdapat lebih dari satu base learner dengan cara kerja sequential/berurutan di mana hasil modeling dari suatu base learner pada sample dari dataset akan mempengaruhi pemilihan sampel dan modeling pada base learner selanjutnya, disebut dengan
- a. Voting

- b. Stacking
 - c. Bagging
 - d. Boosting**
 - e. Tuning
23. Pada model bagging yang menggunakan decision tree sebagai base learner, manakah cara kerja model bagging berikut yang kurang tepat dalam mengoptimalkan prediksi yang dihasilkan?
- a. Menjalankan semua base learner secara parallel
 - b. Melakukan hyperparameter tuning untuk menentukan jumlah base learner yang paling optimal terhadap data
 - c. Menjalankan base learner secara sequential**
 - d. Hasil prediksi dari setiap base learner di-agregasi dengan cara majority vote
 - e. Dilakukan bootstrap-sampling untuk memiliki karakteristik data yang berbeda pada tiap base learner
24. Di bawah ini yang merupakan pernyataan yang kurang tepat mengenai principal component analysis (PCA) yaitu
- a. PCA mengurangi jumlah dimensi data dengan menghapus feature yang korelasinya paling kecil terhadap target**
 - b. Kekurangan dari penerapan PCA adalah adanya risiko kehilangan informasi dari data yang digunakan
 - c. Feature hasil penerapan PCA dapat digunakan untuk clustering
 - d. PCA dapat mempermudah untuk tujuan visualisasi pada 2D atau 3D plot
 - e. PCA dapat menangani multicollinearity
25. Pada metode clustering DBSCAN, Anda bisa mengatur hyperparameter epsilon dan min_samples. Pernyataan yang benar mengenai hal tersebut adalah
- a. Memperbesar nilai epsilon akan menyebabkan cluster yang terbentuk cenderung berukuran kecil-kecil
 - b. Memperbesar nilai epsilon akan menyebabkan semakin sedikit data point yang masuk sebagai cluster
 - c. Memperbesar nilai min_samples akan menyebabkan semakin banyak data yang dianggap sebagai noise**
 - d. Memperbesar nilai min_samples akan mempermudah bagi setiap data untuk menjadi core sample
 - e. Epsilon adalah jumlah minimum sample untuk menjadi core sample
26. Pernyataan yang kurang tepat mengenai K-Means Clustering adalah ...
- a. Cara kerja K-Means Clustering adalah dengan memasukkan data point pada centroid terdekat menjadi sebuah cluster, kemudian pada iterasi berikutnya centroid akan berpindah ke rata-rata pada cluster tersebut
 - b. Jumlah cluster optimal dapat ditentukan menggunakan dendrogram**
 - c. Jumlah cluster optimal dapat ditentukan menggunakan shilouette score

- d. Jumlah cluster optimal dapat ditentukan menggunakan elbow method
- e. Tidak ada jawaban yang benar

27. Apabila sebuah ARIMA model menggunakan satu level differencing dan dua observasi lag sebagai predictor, maka parameter yang digunakan adalah ...

- a. ARIMA(1,2,0)
- b. ARIMA(2,1,2)
- c. ARIMA(0,1,2)
- d. ARIMA(2,1,0)**
- e. ARIMA(0,1,0)

28. Perhatikan beberapa contoh dokumen teks berikut ini.

Doc 1: "Dibutuhkan 2 orang untuk posisis Data Analyst di head office Jakarta"

Doc 2: "Perusahaan ABC sedang membua lowongan Data Engineer. Silakan mengajukan lamaran."

Doc 3: " Saya bermaksud melamar pekerjaan pada perusahaan ini pada posisi Data Scientist"

Anggap datanya telah dibersihkan dan dikembalikan ke kata dasar. Kata yang memiliki bobot TF-IDF terbesar pada dokumen ketiga adalah

- a. lamar
- b. perusahaan
- c. posisi
- d. data
- e. scientist**

29. Diberikan sebuah teks yang sudah di-preprocess seperti berikut ini.

"saya akan membeli pizza"

Apabila tokenization dilakukan menggunakan 2-grams ($\text{min_n} = 2$ dan $\text{max_n} = 2$), maka hasil yang diperoleh adalah

- a. saya akan, akan membeli, membeli pizza**
- b. saya, akan, membeli, pizza, saya akan, akan membeli, membeli pizza
- c. saya akan, membeli pizza
- d. saya, akan, membeli, pizza, saya akan, membeli pizza
- e. Tidak ada yang benar

30. Pada item-based collaborative filtering, pemberian rekomendasi dilakukan dengan ...

- a. Mencari produk P yang memiliki jumlah user terbanyak, sehingga P akan direkomendasi ke semua user U' yang belum menggunakannya
- b. Memberi rekomendasi produk P pada user U berdasarkan produk P' yang mana content produk P paling serupa dengan produk P'

- c. Mencari produk P yang belum pernah digunakan oleh user U, namun telah digunakan oleh user U' yang mirip dengan U, sehingga P akan direkomendasikan kepada U
 - ☒ d. Memberi rekomendasi produk P kepada User U yang menggunakan produk P', di mana produk P' memiliki user U' yang juga merupakan pengguna produk P
 - e. Tidak ada yang benar
31. Di bawah ini, yang merupakan kelemahan dalam penerapan model-based recommender system adalah
- a. Memiliki keterbatasan dalam mengembangkan minat pengguna
 - ☒ b. Akan kesulitan ketika hendak merekomendasikan item-item baru yang belum ada ratingnya
 - c. Item dengan rating paling banyak akan kesulitan direkomendasikan
 - d. Metode ini memerlukan domain knowledge yang spesifik
 - e. Tidak ada yang benar
32. Data maturity level di mana perusahaan memiliki data (menyimpan), kemudian melakukan analisis untuk root cause analysis, mereka juga dapat menggunakan data untuk menjadikannya aset strategi, seperti melakukan prediksi-prediksi kejadian yang ditunjukkan berdasarkan pola saat ini. Hampir seluruh divisi perusahaan sudah mulai melakukan analisis data untuk mengambil keputusan, namun belum berani mengotomasi produk mereka menggunakan data. Perusahaan tersebut termasuk dalam level ...
- a. Data resistant
 - b. Data aware
 - ☒ c. Data guided
 - d. Data savvy
 - e. Data driven
33. Di bawah ini, yang bukan merupakan contoh bentuk deliverable pada interpretable machine learning model adalah ...
- a. Decision Tree plot
 - b. Koefisien dari feature-feature di Linear Regression
 - c. Dendogram pada Hierarchical Clustering
 - d. Decision boundary pada K-Means Clustering
 - ☒ e. Feature Importance pada Gradient Boost
34. Di bawah ini, yang merupakan business question yang bersifat inference yaitu
- a. Apakah kita dapat mendeteksi siapa saja customer yang akan melakukan churn?
 - ☒ b. Kota mana yang menghasilkan pendapatan paling besar?
 - c. Apakah kita dapat mengelompokkan customer berdasarkan segmentasinya?
 - d. Pelanggan mana saja yang baru mulai bertransaksi hari ini dan paling mungkin akan menjadi loyal customer?
 - e. Pelanggan mana saja yang bertransaksi hari ini dan terindikasi melakukan fraud?

35. Berikut adalah evaluation metrics yang biasa digunakan untuk kasus klasifikasi, kecuali...

- a. Recall
- b. F1 score
- c. Accuracy
- d. Precision
- ☒ e. R-square